

# Vettori, Matrici e Dataframe

Test per le organizzazioni

Ottavia M. Epifania

`ottavia.epifania@unipd.it`

Margherita Calderan

`margherita.calderan@unipd.it`

Università di Padova

1 Vettori

2 Fattori

3 Matrici

4 Dataframe











## Tiplogia di vettore

Un vettore deve essere formato da **elementi tutti dello stesso tipo!**

```
wrong = c(1,2,3,"non so", 4)
class(wrong)
```

```
[1] "character"
```

wrong

```
[1] "1"      "2"      "3"      "non so" "4"
```

Altrimenti si “rischia” che tutto venga trasformato a carattere.

```
correct = c(1,2,3,NA, 4)
class(correct)
```

```
[1] "numeric"
```



is.\* & as.\*

Possiamo testare o convertire (quando possibile) la tipologia del vettore attraverso queste funzioni `is.` & `as.`

## Vettore di tipo character

char\_vect

```
[1] "R" "R" "R" "ok"
```

```
is.character(char_vect)
```

```
[1] TRUE
```

```
as.numeric(char_vect) ###
```

```
[1] NA NA NA NA
```

is.\* & as.\*

## Vettore di tipo numeric

num\_vect

[1] 1 2 3 4

```
is.numeric(num_vect)
```

```
[1] TRUE
```

```
as.character(num_vect) ###
```

```
[1] "1" "2" "3" "4"
```

is.\* & as.\*

## Vettore di tipo logical

```
logi_vect = c(TRUE,FALSE,TRUE)
is.logical(logi_vect)
```

```
[1] TRUE
```

```
as.numeric(logi_vect)
```

```
as.numeric(logi_vect)
```

$$[1] \quad 1 \quad 0 \quad 1$$

# 1 Vettori

- Indicizzazione

## 2 Fattori

## 3 Matrici

## 4 Dataframe



```
my_vect[1:5] # estraggo i primi 5 elementi
```

[1] 13 12 28 68 86

```
my_vect[c(1,4,2,9)] # estraggo elementi a scelta
```

[1] 13 68 12 19



## Indicizzazione Logica

Possiamo selezionare elementi dal vettore basandoci su specifiche condizioni logiche: **TRUE** e **FALSE**.

```
numeri = 1:7; numeri
```

```
[1] 1 2 3 4 5 6 7
```

```
numeri>2 & numeri<5
```

```
[1] FALSE FALSE  TRUE  TRUE FALSE FALSE FALSE
```

```
numer1[numer1>2 & numer1<5]
```

[1] 3 4



## Operazioni matematiche sui vettori

Possiamo eseguire operazioni sui vettori, ed applicare la stessa operazione a tutti gli elementi del vettore (element-wise)

```
# ?rep
new_vect = rep(2:4, each = 2)
new_vect
```

[1] 2 2 3 3 4 4

```
# potete svolgere qualsiasi operazione
new_vect/2
```

```
[1] 1.0 1.0 1.5 1.5 2.0 2.0
```

- 1 Vettori
- 2 **Fattori**
- 3 Matrici
- 4 Dataframe

# Fattori

I fattori sono una tipologia di dato peculiare e per quanto simile a semplici **characters** in realtà sono un tipo di vettore **integer** con delle proprietà aggiuntive.





I fattori permettono di avere dei livelli `levels()` come metadati,

```
levels(my_fact)
```

```
[1] "hello" "ciao"  "hola"
```







1 Vettori

2 Fattori

3 **Matrici**

4 Dataframe





## Matrici - Caratteristiche

- Possono contenere **una sola tipologia** di dati
- Essendo **bidimensionali**, abbiamo bisogno di due indici di posizione (righe e colonne) per identificare un elemento
- Possono essere viste come un **insieme** di singoli **vettori**





1 Vettori

2 Fattori

3 **Matrici**

- Matrici - Indicizzazione

4 Dataframe

## Matrici - Indicizzazione

Per identificare uno o più elementi nella matrice abbiamo bisogno di indici/e di riga e/o colonna separati da virgola, sempre con le parentesi quadre: **matrice[riga, colonna]**

```
my_mat
```

	[,1]	[,2]	[,3]	[,4]	[,5]
[1,]	1	3	5	7	9
[2,]	2	4	6	8	10

```
my_mat[1,1]
```

[1] 1



E' possibile anche selezionare un'intera riga o colonna

```
my_mat[1,]
```

```
[1] 1 3 5 7 9
```

```
my_mat[:,1]
```

[1] 1 2









rowbind()

```
rbind(my_mat1, my_mat2)
```

	[,1]	[,2]
[1,]	1	3
[2,]	2	4
[3,]	5	7
[4,]	6	8

Cosa notate di “strano”?

## Operazioni con le matrici

Come per i vettori, anche alle matrici si possono applicare operazioni matematiche:

```
my_mat = matrix(data = 1:4, nrow = 2, ncol = 2)
```

## # element-wise

```
my_mat*my_mat
```

```

      [,1] [,2]
[1,]    1    9
[2,]    4   16

```

## Operazioni con le matrici

Come per i vettori, anche alle matrici si possono applicare operazioni matematiche:

```
# Prodotto matriciale
my_mat%%my_mat
```

```

      [,1] [,2]
[1,]    7  15
[2,]   10  22

```

#  $(1*1 + 3*2)$  ,  $(1*3 + 3*4)$   
#  $(2*1 + 4*2)$  ,  $(2*3 + 4*4)$



- 1 Vettori
- 2 Fattori
- 3 Matrici
- 4 Dataframe**

## Dataframe

Il dataframe è la struttura più “complessa”, utile e potente di R.

- ogni elemento è un **vettore** con un **nome associato** (aka una colonna)
- ogni colonna deve avere lo stesso numero di elementi
- di conseguenza ogni riga ha lo stesso numero di elementi (**struttura rettangolare**)

1 Vettori

2 Fattori

3 Matrici

4 **Dataframe**

- Creazione
- Indicizzazione
- Esempi
- Combinare Dataframes
- Esportazione e importazione dati
- Ora però facciamo un po' di pratica!

# Creazione

Si creano attraverso il comando `data.frame`

```
# Creo un dataframe con 3 colonne
```

```
my_df = data.frame( numeri = 1:4, lettere = letters[1:4],
                    normale = rnorm(n = 4, mean = 0, sd = 1))
my_df
```

	numeri	lettere	normale
1	1	a	1.9683616
2	2	b	0.1965249
3	3	c	0.2451950
4	4	d	-0.9764253

## Attributi

Il `dataframe` ha sia gli attributi della lista ovvero i ***names*** ma anche gli attributi della matrice ovvero le ***dimensioni*** (righe e colonne)

```
attributes(my_df)
```

\$names

```
[1] "numeri"  "lettere" "normale"
```

\$class

```
[1] "data.frame"
```

\$row.names

[1] 1 2 3 4

```
dim(my_df)
```

Possiamo utilizzare le funzioni `names()`, `dim()`, `nrow()`, `ncol()`... per ottenere informazioni sulle caratteristiche del dataframe. La funzione più utile è `str()` poichè ci restituisce una veloce overview della struttura del dataframe: dimensioni, tipi di variabili,...

```
str(my_df)
```

```
'data.frame':  4 obs. of  3 variables:
 $ numeri : int  1 2 3 4
 $ lettere: chr  "a" "b" "c" "d"
 $ normale: num  1.968 0.197 0.245 -0.976
```

1 Vettori

2 Fattori

3 Matrici

4 **Dataframe**

- Creazione
- Indicizzazione
- Esempi
- Combinare Dataframes
- Esportazione e importazione dati
- Ora però facciamo un po' di pratica!

## Indicizzazione

```
my_df[1]    # estraggo un data.frame 5x1
```

	numerical
1	1
2	2
3	3
4	4

```
my_df[[1]] # estraggo la prima colonna del data.frame
```

```
[1] 1 2 3 4
```

```
my_df[1,1] # estraggo il primo elemento della prima colonna del
```

[1] 1



## Indicizzazione \$

```
my_df$numeri # estraggo la prima colonna del data.frame
```

[1] 1 2 3 4

```
my_df$numeri[1] # estraggo il primo elemento della prima colonna
```

[1] 1



1 Vettori

2 Fattori

3 Matrici

4 Dataframe

- Creazione
- Indicizzazione
- Esempi
- Combinare Dataframes
- Esportazione e importazione dati
- Ora però facciamo un po' di pratica!

## Esempi

```
my_df
```

	numeri	lettere	normale
1	1	a	1.9683616
2	2	b	0.1965249
3	3	c	0.2451950
4	4	d	-0.9764253

```
my_df[my_df$numeri > 2 & my_df$numeri < 4, ]
```

	numeri	lettere	normale
3	3	c	0.245195

```
my_df[my_df$numeri== 2, 2]
```

```
character(0)
```

## Indicizzazione subset()

```
str(iris)
```

```
'data.frame': 150 obs. of 5 variables:
```

```
$ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
```

```
$ Sepal.Width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
```

```
$ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ..
```

```
$ Petal.Width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ..
```

```
$ Species : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1
```

```
subset(iris, subset = Species == "setosa" & Petal.Length > 1.7)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
25	4.8	3.4	1.9	0.2	setosa
45	5.1	3.8	1.9	0.4	setosa

Equivalente a:

```
iris[iris$Species == "setosa" & iris$Petal.Length > 1.7,]
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
25	4.8	3.4	1.9	0.2	setosa
45	5.1	3.8	1.9	0.4	setosa

## subset(df, select = ...)

E' possibile anche selezionare colonne piuttosto che righe attraverso l'argomento *select*:

```
subset(iris, select = c(Sepal.Length, Species))
```

```
#visualizzo le prime due righe attraverso il comando head  
head(subset(iris, select = c(Sepal.Length, Species)), n = 3)
```

	Sepal.Length	Species
1	5.1	setosa
2	4.9	setosa
3	4.7	setosa

```
subset(df, subset = ..., select = ...)
```

Possiamo anche combinare le due cose:

```
subset(iris, subset = Species == "setosa" & Sepal.Length > 4, sel
```

```
head(subset(iris, subset = Species == "setosa" & Sepal.Length > 4
```

	Sepal.Length	Species
1	5.1	setosa
2	4.9	setosa
3	4.7	setosa



La maggiorparte delle volte vi troverete ad accedere alle variabili tramite l'operatore \$. Questo comando può essere utilizzato anche per creare una nuova variabile...

```
# creo una variabile che è la somma di Length e Width  
iris$somma = iris$Sepal.Length + iris$Sepal.Width
```

```
str(iris)
```

```
'data.frame':   150 obs. of  6 variables:  
 $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...  
 $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...  
 $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ..  
 $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ..  
 $ Species      : Factor w/ 3 levels "setosa","versicolor",...: 1 1 ...  
 $ somma        : num  8.6 7.9 7.9 7.7 8.6 9.3 8 8.4 7.3 8 ...
```

Si applicano gli stessi concetti che abbiamo visto per i vettori, potete quindi sia creare che modificare variabili.

```
my_df = data.frame(num = 1:4, let = letters[1:4])  
my_df
```

	num	let
1	1	a
2	2	b
3	3	c
4	4	d

```
# Modifico la variabile num aggiungendo 1  
my_df$num = my_df$num+1
```

```
# Creo una terza variabile composta dalla varibile num e let  
my_df$both = paste(my_df$num,my_df$let, sep = "_") # ?paste
```

1 Vettori

2 Fattori

3 Matrici

4 **Dataframe**

- Creazione
- Indicizzazione
- Esempi
- Combinare Dataframes
- Esportazione e importazione dati
- Ora però facciamo un po' di pratica!

## Combinare Dataframes

Essendo simili a delle matrici, i dataframe si possono combinare tra loro attraverso le funzioni `rbind()`:

```
# primo dataframe  
str(my_df)
```

```
'data.frame':   4 obs. of   3 variables:  
 $ num : num   2 3 4 5  
 $ let : chr  "a" "b" "c" "d"  
 $ both: chr  "2_a" "3_b" "4_c" "5_d"
```

```
# creo un secondo dataframe  
my_df2 = data.frame(num = 4:7, lett = letters[1:4],  
                    both = paste(4:7, letters[1:4], sep = "_"))
```

```
str(my_df2)
```

## Unisco i due dataframes

- I dataframes devono avere lo stesso numero di colonne
- I nomi delle colonne devono essere identici

```
my_df3 = rbind(my_df,my_df2)
```

```
Error in `match.names()`:  
! names do not match previous names
```

```
str(my_df)
```

```
'data.frame':   4 obs. of  3 variables:  
 $ num : num  2 3 4 5  
 $ let : chr  "a" "b" "c" "d"  
 $ both: chr  "2_a" "3_b" "4_c" "5_d"
```

```
str(my_df2)
```

## Sistema i nomi

```
names(my_df2)
```

```
[1] "num" "lett" "both"
```

```
names(my_df)
```

```
[1] "num" "let" "both"
```

```
# voglio che i names di my_df2 corrispondano ai names di my_df  
names(my_df2) = names(my_df)
```

```
my_df3 = rbind(my_df, my_df2)  
str(my_df3)
```

```
'data.frame': 8 obs. of 3 variables:
```

```
$ num : num 2 3 4 5 4 5 6 7
```

```
$ let : chr "a" "b" "a" "d"
```

Potrebbe anche capitarvi di dover raccogliere differenti tipi di dato dallo stesso partecipante, e successivamente combinare le informazioni raccolte...

```
df_rt = data.frame(subj = factor(rep(c("caio", "tizio"), each = 400),
                                cond = factor(rep(c("easy", "hard"),
                                                    each = 200, times = 2)),
                    rt = c(rlnorm(n = 400, meanlog = -1, sdlog = 1),
                          rlnorm(n = 400, meanlog = -.7, sdlog = 1)))
```



Dataframe contente l'età:

```
df_age = data.frame(subj = factor(c("caio","tizio")), age = c(20
```

```
str(df_rt) # struttura dataframe tempi di reazione
```

```
'data.frame':  800 obs. of  3 variables:
 $ subj: Factor w/ 2 levels "caio","tizio": 1 1 1 1 1 1 1 1 1 1
 $ cond: Factor w/ 2 levels "easy","hard": 1 1 1 1 1 1 1 1 1 1 .
 $ rt  : num  0.212 0.306 0.244 0.259 0.343 ...
```

```
head(df_rt)
```

```
      subj cond      rt
1 caio easy 0.2124034
2 caio easy 0.3061848
3 caio easy 0.2437760
4 caio easy 0.2587453
5 caio easy 0.3433939
6 caio easy 0.3356226
```

```
str(df_age) # struttura dataframe età
```

In questo caso, è possibile utilizzare la funzione `merge()`:

```
df_all_1 = merge(x = df_rt, y = df_age, by="subj")
str(df_all_1)
```

```
'data.frame':   800 obs. of  4 variables:
 $ subj: Factor w/ 2 levels "caio","tizio": 1 1 1 1 1 1 1 1 1 1
 $ cond: Factor w/ 2 levels "easy","hard": 1 1 1 1 1 1 1 1 1 1
 $ rt  : num  0.212 0.306 0.244 0.259 0.343 ...
 $ age : num  20 20 20 20 20 20 20 20 20 20 ...
```

la funzione `_join()`:

```
library(dplyr) # carico il pacchetto dplyr
```

```
df_all_2 = left_join(x = df_rt, y = df_age, by = c("subj")) # es  
str(df_all_2)
```

```
'data.frame': 800 obs. of 4 variables:
```

```
$ subj: Factor w/ 2 levels "caio","tizio": 1 1 1 1 1 1 1 1 1 1
```

```
$ cond: Factor w/ 2 levels "easy","hard": 1 1 1 1 1 1 1 1 1 1 .
```

```
$ rt : num 0.212 0.306 0.244 0.259 0.343 ...
```

```
$ age : num 20 20 20 20 20 20 20 20 20 20 ...
```

1 Vettori

2 Fattori

3 Matrici

4 **Dataframe**

- Creazione
- Indicizzazione
- Esempi
- Combinare Dataframes
- Esportazione e importazione dati
- Ora però facciamo un po' di pratica!

## Esportazione e importazione dati

In R è possibile importare dati in molti formati differenti, più comunemente vi troverete ad importare dati **.csv** oppure **.xlsx**.

Qui per esempio, esporto i dataframe in tre formati differenti...

```
library(readr) # carico il pacchetto readr
library(writexl) # carico il pacchetto writexl

write.csv(df_rt, file = "data/df_rt.csv", row.names = FALSE)
write_xlsx(df_age, path = "data/df_age.xlsx")
save(df_age, file = "data/df_age.rda") # formato R
```



## Controllo la struttura ed il tipo di dati

```
str(df_rt_impo)
```

```
spec_tbl_ [800 x 3] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ subj: chr [1:800] "caio" "caio" "caio" "caio" ...
 $ cond: chr [1:800] "easy" "easy" "easy" "easy" ...
 $ rt   : num [1:800] 0.212 0.306 0.244 0.259 0.343 ...
- attr(*, "spec")=
 .. cols(
 ..   subj = col_character(),
 ..   cond = col_character(),
 ..   rt   = col_double()
 .. )
- attr(*, "problems")=<externalptr>
```

```
df_rt_impo$subj = as.factor(df_rt_impo$subj)
```



1 Vettori

2 Fattori

3 Matrici

4 **Dataframe**

- Creazione
- Indicizzazione
- Esempi
- Combinare Dataframes
- Esportazione e importazione dati
- Ora però facciamo un po' di pratica!

Ora però facciamo un po' di pratica!

# Ora però facciamo un po' di pratica!

Aprite e tenete aperto questo link:

<https://etherpad.wikimedia.org/p/arca-corsoR>