Indici di Variabilità e di Posizione

Test per le organizzaioni

Ottavia M. Epifania
ottavia.epifania@unipd.it

Margherita Calderan
margherita.calderan@unipd.it

Università di Padova

1 Indici di variabilità

2 I percentili

3 Meglio la media e la deviazione standard, o i percentili?

4 Credits

1 Indici di variabilità

- Campo di variazione
- La varianza
- La deviazione standard
- Il coefficiente di variazione
- I quantili e la differenza interquartilica

2 I percentili

3 Meglio la media e la deviazione standard, o i percentili?

4 Credits

Indici di variabilità

- Il concetto di variabilità si riferisce a quanto i punteggi di una distribuzione sono sparsi ovvero quanto siano simili o dissimili tra loro,
- Il ricorso ad un indice di tendenza centrale comporta una forte semplificazione, e da solo non fornisce informazioni esaurienti sulla distribuzione.
- E' fondamentale capire quanto i dati siano dispersi intorno all'indice di tendenza centrale.
- La variabilità è una caratteristica fondamentale delle distribuzioni "*Variability is the essence of statistics*" (Cobb, 1992)

Consideriamo i risultati dei compiti di Psicometria ottenuti dagli studenti di tre diversi Professori:

```
prof1 = c(18, 22, 24, 16, 19, 22 , 18, 21)
mean(prof1)
```

```
[1] 20
```

```
prof2 = c(10, 10, 12, 10, 30, 28 , 30, 30)
mean(prof2)
```

```
[1] 20
```

```
prof3 = c(20, 20, 20, 20, 20, 20 , 20, 20)
mean(prof3)
```

```
[1] 20
```

In ciascun gruppo di studenti la media dei voti è pari a 20, ma è evidente una diversa dispersione intorno a tale valore.

Indici di variabilità o disperisione

- Dobbiamo quindi considerare la variabilità (o dispersione) di una distribuzione di dati.
- Gli indici di variabilità possono assumere solo valori positivi (non ha senso parlare di dispersione negativa) o nulli (quando i dati osservati hanno tutti lo stesso valore).
- La variabilità minima possibile è 0 e si riferisce a distribuzioni in cui tutti i punteggi sono uguali e dunque non c'è variabilità nei dati.

Campo di variazione

Campo di variazione (o gamma) di una distribuzione di dati è la differenza tra il valore massimo e il valore minimo osservato:

$$\text{gamma} = X_{max} - X_{min}$$

```
prof1
```

```
[1] 18 22 24 16 19 22 18 21
```

```
max(prof1) - min(prof1)
```

```
[1] 8
```

Esempio 2:

```
prof4 = c(10, 30, 27, 29, 30, 28, 30, 30)
prof5 = c(10, 10, 16, 17, 30, 20, 21, 30)

max(prof4) - min(prof5)
```

```
[1] 20
```

```
max(prof4) - min(prof5)
```

```
[1] 20
```

Commenti?

La varianza

- La varianza σ^2 di un insieme di dati è la media degli scarti al quadrato tra i dati e la media dei dati stessi:

$$\sigma^2 = \frac{\sum_i^n (X_i - \bar{X})^2}{n}$$

La varianza assume valore minimo 0 quando tutti i dati sono uguali tra loro e aumenta all'aumentare della dispersione dei dati rispetto alla media:

$$\sigma^2 \geq 0$$

Qual'è la varianza maggiore? Quant'è la varianza di prof3?

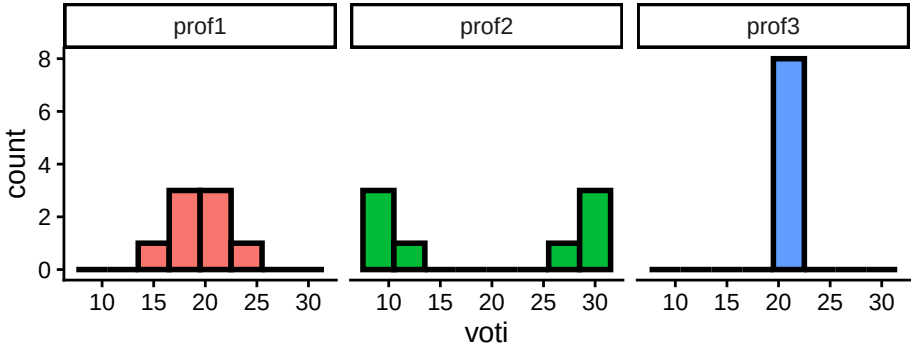

Calcolo della varianza

$$\sigma^2 = \frac{\sum_i^n (X_i - \bar{X})^2}{n}$$

```
prof1
```

```
[1] 18 22 24 16 19 22 18 21
```

Il divisore è il numero di osservazioni: $n = 8$

```
divisore = length(prof1) # numero di osservazioni
```

$$\sigma^2 = \frac{\sum_i^8 (X_i - \bar{X})^2}{8}$$

Calcoliamo la **media** $\bar{X}$

```
media = mean(prof1)
media
```

```
[1] 20
```

$$\sigma^2 = \frac{\sum_i^8 (X_i - 20)^2}{8}$$

Il dividendo è dato dalla **somma dei quadrati degli scarti dalla media** aritmetica:

$$(18-20)^2+(22-20)^2+(24-20)^2+(16-20)^2+(19-20)^2+(22-20)^2+(18-20)^2+(21-20)^2$$

```
prof1
```

```
[1] 18 22 24 16 19 22 18 21
```

```
media
```

```
[1] 20
```

```
# ad ogni elemento di prof1 viene sottrata la media
(prof1-media)^2
```

```
[1]  4  4 16 16  1  4  4  1
```

```
dividendo = sum((prof1-media)^2)
```

La varianza è la **media dei quadrati degli scarti dalla media** aritmetica:

```
dividendo # 4 + 4 + 16 + 16 + 1 + 4 + 4 + 1
```

```
[1] 50
```

```
divisore
```

```
[1] 8
```

```
varianza = dividendo/divisore # varianza descrittiva
varianza
```

```
[1] 6.25
```

$$\sigma^2 = \frac{\sum_i^8 (X_i - 20)^2}{8}$$

La deviazione standard

La deviazione standard (o scarto quadratico medio) è la radice della varianza:

$$\sigma = \sqrt{\sigma^2}$$

Riporta l'indice di varibilità sulla scala della variabile.

Es. In campione di 20 soggetti è stata rilevata la variabile peso. In tale campione la media è pari a $70kg$ e la deviazione standard è pari a 10.7. Si potrà affermare che i soggetti **differiscono mediamente** di $10.7kg$ **dal peso medio** di $70kg$.

Il coefficiente di variazione

Il coefficiente di variazione è dato dal rapporto tra la **deviazione standard** e il **valore assoluto della media** dei dati:

$$CV = \frac{\sigma}{|\bar{X}|}$$

Il **CV** è un indice di variabiltà relativa che **tiene conto**, oltre che della **deviazione standard** dei dati, anche della **media**. Per questo motivo è molto utile per eseguire dei confronti in termini di **variabilità tra fenomeni "diversi" tra loro**.

A un gruppo di 15 studenti viene somministrato un test che valuta le conoscenze informatiche generali (20 domande, del tipo *giusto/sbagliato*). I 15 studenti seguono un corso di informatica generale organizzato dal Comune e a fine corso viene somministrato loro un test sulle conoscenze informatiche. Il test prevede 40 domande del tipo *giusto/sbagliato*. I risultati dei due test, in termini di media e deviazione standard di risposte corrette, sono presentati nella seguente tabella:

Test	media	deviazione standard
Pre-test	9	5
Post-test	30	8

C'è più variabilità tra i soggetti al pre-test o al post-test?

- Naturalmente confrontare le deviazioni standard non è di grande aiuto. Esse dipendono fortemente dalle media dei dati su cui sono state calcolate.
- Per poter operare un confronto sulla variabilità dei punteggi ottenuti ai due test è opportuno calcolare i rispettivi coefficienti di variazione:

$$CV_{\text{pre-test}} = \frac{5}{9} = .56$$

$$CV_{\text{post-test}} = \frac{8}{30} = .27$$

Osservando i risultati si può concludere che le conoscenze informatiche dei soggetti sono più omogenee al post-test.

I quantili e la differenza interquartilica

La differenza interquartilica di una distribuzione è la differenza tra il terzo e il primo quartile (o equivalentemente tra il 75—esimo e il 25—esimo percentile) dei dati:

$$IQR = Q_{75} - Q_{25}$$

Cosa vuol dire?

Immaginiamo di avere i voti di 200 studenti:

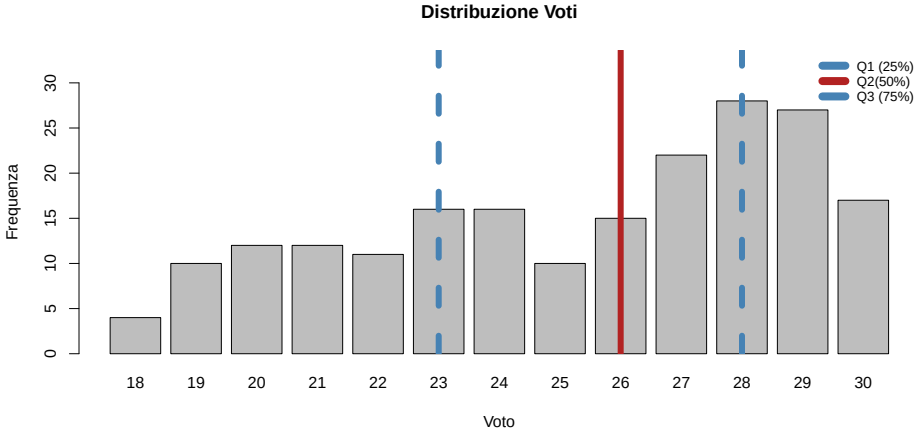

Boxplot

Outlier: valori che distano da Q25

più di una volta e mezzo

la distanza tra Q75−Q25

(ie., la differenza interquartilica)

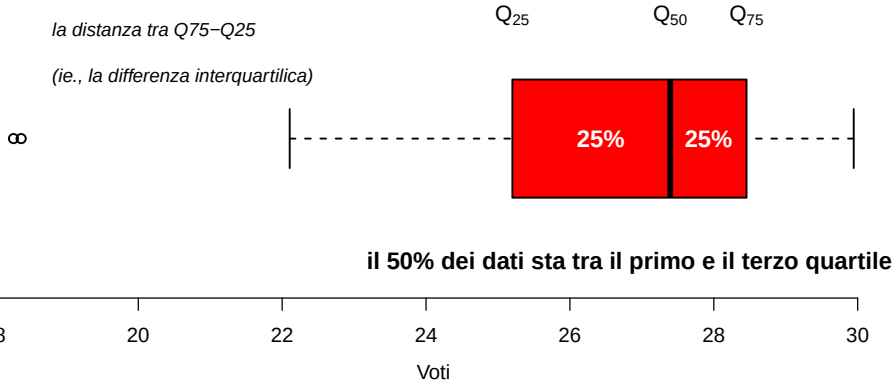

La differenza interquartilica

La differenza interquartilica (IQR) misura la dispersione del 50% centrale dei dati (tra primo e terzo quartile), quindi i valori estremi incidono poco o per nulla sul suo valore. Per questo è chiamato un indice di variabilità robusto.

```
IQR(voti) # funzione per il calcolo automatico
```

```
[1] 3.235585
```

Outilier

- I baffi si estendono fino all'ultimo dato entro 1.5 volte l'IQR dai quartili. Tutto ciò che sta oltre i baffi è un outlier.
- Un outlier è un valore che dista dai quartili (Q_1 o Q_3) più di 1.5 volte la differenza interquartile (IQR).
- È un outlier qualsiasi osservazione che cade fuori dall'intervallo $[Q_1 - 1.5 \times IQR \quad ; \quad Q_3 + 1.5 \times IQR]$.

1 Indici di variabilità

2 I percentili

3 Meglio la media e la deviazione standard, o i percentili?

4 Credits

1 Indici di variabilità

2 I percentili

- Dati
- Rango percentile
- Qual è la differenza tra `rank()` e `order()`?

3 Meglio la media e la deviazione standard, o i percentili?

4 Credits

Dati

Il dataset sintetico contiene dati individuali relativi a dipendenti di un'azienda e viene utilizzato per modellare il rischio di burnout e analizzare i fattori associati al benessere lavorativo.

Utilizzeremo i dati sul burnout, concentrandoci ad esempio sul livello di soddisfazione (`SatisfactionLevel`):

```
# Carichiamo i dati dal file fornito
library(readr)
burnout=read_csv("data/burnout.csv")
soddisfazione=burnout$SatisfactionLevel
```

Per parlare di percentili/quantili dobbiamo prima ordinare i dati dal più basso al più alto.

```r
head(soddisfazione, n = 6) # prime 6 risposte
```

```
[1] 4.40 2.09 2.58 3.23 4.41 4.31
```

```r
tail(soddisfazione, n = 6) # ultime 6 risposte
```

```
[1] 2.68 3.40 4.67 4.10 2.11 4.36
```

Per parlare di percentili/quantili dobbiamo prima ordinare i livelli di soddisfazione dal più basso al più alto:

```
s_sorted = sort(soddisfazione) # riordino ?sort

head(s_sorted, n = 6) # primi 6 valori
```

```
[1] 1.00 1.01 1.01 1.01 1.01 1.01
```

```
tail(s_sorted, n = 6) # ultimi 6 valori
```

```
[1] 4.99 4.99 5.00 5.00 5.00 5.00
```

Trovare il valore sotto cui cade circa il 25% dei punteggi di soddisfazione.

$$Pos_p = \frac{n+1}{100} \cdot p$$

```
n = length(soddisfazione) # numero di osservazioni

p = 25 # voglio il 25° percentile

pos_p = ((n+1)/100) * p  #Posizione di ordine p

p_25 = s_sorted[pos_p] # prendo il valore in quella posizione
p_25
```

```
[1] 2
```

Fortunatamente esiste la funzione `quantile()` che permette di calcolare i quantili:

```
# probs specifica che quantili vogliamo
quantile(soddisfazione, probs = c(0.05, 0.25,0.50,0.75, 0.95))
```

```
    5%     25%     50%     75%     95%
1.2100 2.0000 3.0250 4.0000 4.7905
```

Esempio

Il livello di soddisfazione di 6 lavoratori è riportato nella tabella seguente:

Codice partecipante	1	2	3	4	5	6
Punteggio	3.65	4.90	1.06	2.93	3.10	4.97

Valutare i livelli di soddisfazione dei 6 dipendenti alla luce dei valori del campione:

Percentile	P5	P25	P50	P75	P95
Punteggio	1.210	2.000	3.025	4.000	4.7905

Rango percentile

Il **Rango percentile** (Rp) indica la **percentuale di casi** che hanno un **valore uguale o inferiore** a un particolare punteggio X_i

Per i dipendenti del reparto `Sales`, a 39 ore di lavoro settimanali è associato il rango percentile di 25 ($Rp_{39} = 50$).

Il **50%** dei dipendenti del reparto `Sales` lavora un numero di ore settimanali inferiore o uguale a 39.

Supponiamo di aver intervistato un dipendente e di aver verificato che il suo numero di ore lavorative equivale a un rango percentile pari a 5.

Come interpretare il suo carico di lavoro?

Calcolo dei ranghi percentili

Per calcolare un rango percentile, basta seguire questi semplici step:

1. Determinare quanti casi sono nel gruppo.
2. Determinare quanti casi cadono "sotto" o al punteggio di interesse.
3. Dividere il numero di casi ottenuti allo step 2 per il numero totale di casi nel gruppo (step 1)
4. Moltiplicare il risultato dello step 3 per 100

Rango percentile

$$P_r = \frac{B}{N} \times 100 = \text{rango percentile di } X_i$$

- X_i = punteggio di interesse
- N = numero totale di casi
- B = numero di casi $\leq X_i$
- P_r = rango percentile

Utilizziamo i dati del file `burnout.csv` per analizzare le ore di lavoro settimanali (`WorkHoursPerWeek`).

```
# Visualizziamo le prime righe del dataset relative a questa variabile
head(burnout$WorkHoursPerWeek)
```

```
[1] 60 47 44 44 38 44
```

Supponiamo che il nostro caso di interesse sia un dipendente che lavora 47 ore a settimana (es. Max Wang dalla seconda riga del file). Prima di tutto riordiniamo i dati in ordine crescente.

```
burnout_sorted = sort(burnout$WorkHoursPerWeek)
```

```
head(burnout$WorkHoursPerWeek) #prima
```

```
[1] 60 47 44 44 38 44
```

```
head(burnout_sorted) #dopo
```

```
[1] 30 30 30 30 30 30
```

Calcoliamo il rango percentile per il dipendente che lavora 47 ore settimanali:

$$P_r = \frac{B}{N} \times 100 = \text{rango percentile di } X_i$$

```
# numero di casi minori o uguali a 47 ore
(B = sum(burnout_sorted <= 47))
```

```
[1] 914
```

```
# numero di casi totali
(N = length(burnout_sorted))
```

```
[1] 2000
```

```
(P = (B/N) * 100)
```

```
[1] 45.7
```

Il 45.7% per cento dei dipendenti lavora un numero di ore pari o inferiore a

In R è possibile utilizzare direttamente la funzione `rank()`: *"Qual è il **rango** (la posizione relativa) di ciascun candidato rispetto al resto del gruppo?"*

```
rango = rank(burnout$WorkHoursPerWeek)
head(rango) # indica l'ordine crescente (mostriamo i primi 6)
```

```
[1] 1521.0  889.5  732.5  732.5  427.5  732.5
```

```
(N = nrow(burnout)) # quante osservazioni totali
```

```
[1] 2000
```

Rango percentile

```r
# aggiungo la variabile Pr al dataset
burnout$Pr_WorkHours = rango / N
# divido l'indice di posizione per il valore totale

head(burnout[, c("Name", "WorkHoursPerWeek", "Pr_WorkHours")])
```

```
# A tibble: 6 x 3
  Name         WorkHoursPerWeek Pr_WorkHours
  <chr>                   <dbl>        <dbl>
1 Max Ivanov                 60        0.760
2 Max Wang                   47        0.445
3 Nina Petrov                44        0.366
4 John Ivanov                44        0.366
5 John Wang                  38        0.214
6 Lily Smith                 44        0.366
```

Qual è la differenza tra `rank()` e `order()`?

Entrambe le funzioni riguardano l'ordinamento, ma rispondono a due domande diverse in fase di analisi dei dati:

- `order()` risponde a: *"Quali **indici di riga** del dataset devo selezionare, e in che sequenza, per ordinare i punteggi dal più basso al più alto?"*
- `rank()` risponde a: *"Qual è il **rango** (la posizione relativa) di ciascun candidato rispetto al resto del gruppo?"*

Qual è la differenza tra `rank()` e `order()`?

```r
# Punteggi di tre candidati a un test attitudinale
punteggi = c(30, 18, 25)

# order: per ordinare il vettore, devo prendere prima
# il 2° valore (18), poi il 3° (25), e infine il 1° (30)
order(punteggi)
```

```
[1] 2 3 1
```

```r
# rank: il primo candidato (30) ha il rango più alto (3),
# il secondo (18) ha il rango più basso (1),
# il terzo (25) ha rango 2
rank(punteggi)
```

```
[1] 3 1 2
```

Qual è la differenza tra `rank()` e `order()`?

I decimali compaiono in `rank()` quando ci sono dei punteggi identici.

Se due candidati ottengono lo stesso punteggio al test, la funzione risolve la parità calcolando la media dei ranghi che i due punteggi avrebbero occupato.

```
# Due candidati ottengono 25 (occupano il 2° e 3° rango teorico)
punteggi_simili = c(18, 25, 25, 30)

# (2 + 3) / 2 = 2.5.
# Entrambi i candidati con 25 ottengono il rango 2.5
rank(punteggi_simili)
```

```
[1] 1.0 2.5 2.5 4.0
```

Qual è la differenza tra `rank()` e `order()`?

`order()` restituisce gli indici necessari a riordinare fisicamente un dataset. Poiché non si può chiedere a R di estrarre la "riga 2.5" di un dataframe, `order()` restituisce solo numeri interi (quando ci sono punteggi identici, li ordina semplicemente in base a chi compare per primo nel file).

Qual è la differenza tra `rank()` e `order()`?

1 Indici di variabilità

2 I percentili

3 Meglio la media e la deviazione standard, o i percentili?

4 Credits

1 Indici di variabilità

2 I percentili

3 Meglio la media e la deviazione standard, o i percentili?

- Media e mediana

4 Credits

Meglio la media e la deviazione standard, o i percentili?

- Il ricorso alla media e alla deviazione standard è tanto più vantaggioso e utile quando la distribuzione della variabile di interesse nel campione di riferimento (che deve essere rappresentata graficamente nel manuale!) è approssimativamente normale.
- Negli altri casi (distribuzioni fortemente asimmetriche) è più conveniente utilizzare i percentili. Tali indici sono infatti definiti "robusti" perchè risentono meno delle caratteristiche della distribuzione della variabile oggetto di studio.
- Spesso nei manuali dei test vengono forniti sia media e deviazione standard che i percentili, in modo da poter garantire una valutazione delle performance il più completa possibile.

Media e mediana

Per capire perché i percentili sono "robusti", calcoliamo la media e la mediana (il 50° percentile) del livello di Experience.

```
media = mean(burnout$Experience)
mediana = median(burnout$Experience)

cat("Media:", round(media, 2), "\n")
```

```
Media: 10.07
```

```
cat("Mediana:", mediana, "\n")
```

```
Mediana: 7
```

Media e mediana

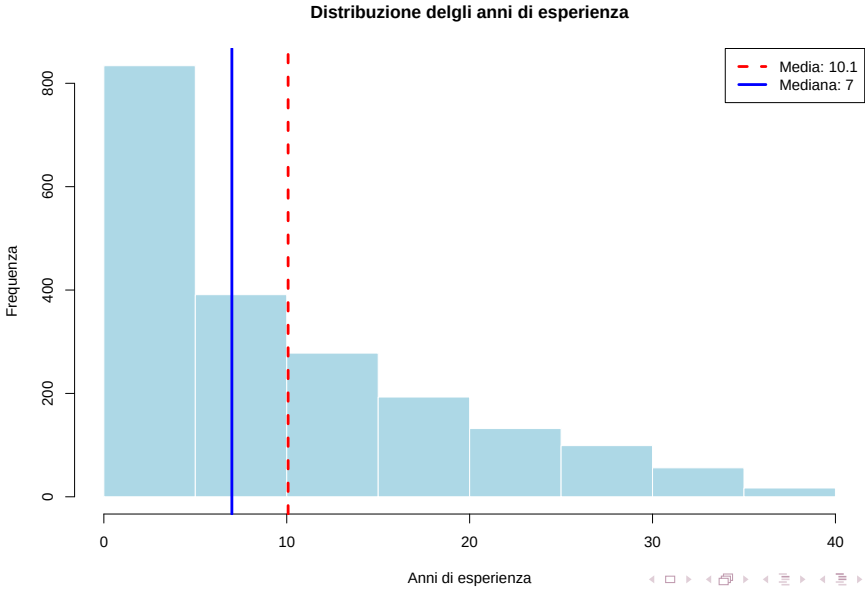

Media e mediana

```r
# Creazione dell'istogramma
hist(burnout$Experience,
     main = "Distribuzione delgli anni di esperienza",
     xlab = "Anni di esperienza",
     ylab = "Frequenza",
     col = "lightblue",
     border = "white")

# Aggiungiamo le linee per media e mediana
# Media in rosso tratteggiato
abline(v = media, col = "red", lwd = 3, lty = 2)
# Mediana in blu continuo
abline(v = mediana, col = "blue", lwd = 3)

# Aggiungiamo una legenda
legend("topright",
       legend = c(paste("Media:", round(media, 1)),
                  paste("Mediana:", mediana)),
       col = c("red", "blue"), lty = c(2, 1), lwd = 3)
```

1 Indici di variabilità

2 I percentili

3 Meglio la media e la deviazione standard, o i percentili?

4 Credits

1 Indici di variabilità

2 I percentili

3 Meglio la media e la deviazione standard, o i percentili?

4 Credits

Credits

Altoè, G. (2022). Corso di Testing Psicologico, Scienze psicologiche dello sviluppo, della personalità e delle relazioni interpersonali, A.A. 2022/23

Marci, M. (2025). Corso di Testing Psicologico, Scienze psicologiche dello sviluppo, della personalità e delle relazioni interpersonali, A.A. 2025/26

Fonte dati