Modulo Didattico 3: Test, scale di risposta, validità e attendibilità

Test per le organizzazioni

Ottavia M. Epifania
ottavia.epifania@unipd.it
Margherita Calderan
margherita.calderan@unipd.it

Università di Padova

A.A.: 2025/2026

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

1 Test
- Cosa sono i test?
- Perché i test?
- Come è fatto un test?
- A cosa servono?
- Dove si usano?
- Come si costruisce un test?

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

British Psychological Society

A psychological test is any procedure on the basis of which inferences are made concerning a **person's capacity, propensity or liability** to act, react, experience, or to structure or order thoughts or behaviours in particular ways

Australian Psychological Society

A psychological test is a set of **standard items or stimuli**, the **responses to which form the basis** for an *inference* which goes *beyond item content* and for which psychologists accept **ethical responsibility** in professional use

I test misurano alcuni aspetti del comportamento attraverso metodi di somministrazione, di scoring e di interpretazione altamente standardizzati e controllati

I comportamenti vengono registrati e interpetati secondo le procedure specifiche di ogni test → vengono espressi *sinteticamente* in un indice numerico

Possono misurare diversi aspetti della persona:

- Emozioni, personalità, atteggiamenti ecc → **test di prestazione tipica**
- Intelligenza, abilità, → **test di prestazione massima**

Queste caratteristiche possono essere distinte in:

- **Tratti**: caratteristiche stabili della persone che difficilmente mutano con il tempo (o che richiedono molto tempo per cambiare)
- **Stati**: caratteristiche transitorie elicitate da particolare situazioni

1 Test
- Cosa sono i test?
- Perché i test?
- Come è fatto un test?
- A cosa servono?
- Dove si usano?
- Come si costruisce un test?

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

Somministrazione di stimoli/domande standard predefiniti → Gli effetti di distorsione dovuti ad elementi estranei sono ridotti

L'analisi delle risposte è un processo aperto e standardizzato → replicabile da chiunque

I test sono – devono essere:

- Affidabili: Costanti nella loro prestazione
- Validi: Misurano quello che dicono di misurare e non altro

1 Test
- Cosa sono i test?
- Perché i test?
- Come è fatto un test?
- A cosa servono?
- Dove si usano?
- Come si costruisce un test?

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

- **Manuale**: Contiene i riferimenti teorici (quadro teorico di riferimento) entro cui è stato sviluppato il test, le informazioni circa la popolazione target e il campione rappresentativo e normativo, le procedure utilizzate per lo sviluppo, le istruzioni di somministrazione, registrazione delle risposte, le procedure da usare per lo scoring e le norme per la trasformazione dei punteggi grezzi in punteggi standardizzati
- **Materiale stimolo**: Le domande/gli stimoli
- **Foglio di notazione**: per registrare le risposte
- **Griglia per la correzione:** come ottenere i punteggi

1 Test
- Cosa sono i test?
- Perché i test?
- Come è fatto un test?
- A cosa servono?
- Dove si usano?
- Come si costruisce un test?

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

Ad ottenere dai soggetti delle prestazioni nella situazione contingente (ATTENZIONE!)

A partire da quelle prestazioni si dovrebbe poter arrivare a una *generalizzazione* al comportamento *fuori dalla situazione sperimentale*, permettendo quindi previsioni relative alla vita quotidiana

- Fare valutazioni (rispetto a diversi costrutti)
- Fare diagnosi (sono **uno** degli strumenti che supportano la diagnosi, il test in sé non fa la diagnosi)
- Prendere delle decisioni

1 Test
- Cosa sono i test?
- Perché i test?
- Come è fatto un test?
- A cosa servono?
- Dove si usano?
- Come si costruisce un test?

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

Ambito educativo

Test di intelligenza, test di profitto
Possono aiutare a migliorare la progettazione didattica o a individuare studenti con particolari difficoltà (o con particolari talenti → plusdotazione)

Ambito sanitario

Fini diagnostici e di cura
Non solo intelligenza, ma anche aspetti legati alla personalità, all'emotività

Ambito organizzativo

Screening del personale attraverso (spesso) test di intelligenza e test specifici per l'azienda

1 Test
- Cosa sono i test?
- Perché i test?
- Come è fatto un test?
- A cosa servono?
- Dove si usano?
- Come si costruisce un test?

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

Fase I: Sviluppo

- **Definizione <u>chiara</u>** del costrutto che si vuole misurare ed esplicitazione del quadro di riferimento teorico e metodologico
  - Cosa va incluso/escluso dal dominio di contenuto del costrutto
  - Sfaccettature e dimensioni del costrutto (aspetto –frequenza/intensità–, modalità –pensiero, comportamento–, tempo, situazioni)
- **Individuazione degli indicatori** $\rightarrow$ definizione del dominio di contenuto del test
- **Formalizzazione degli stimoli**

Fase II: Validazione I

Studio preliminare

Somministrazione "pilota" a un campione di soggetti ($n \approx 100$)
Analisi preliminari delle statistiche descrittive degli item e del punteggio totale al test, ad esempio:

- Verifica delle ridondanze tra gli item
- Risposte mancanti
- Commenti riferiti dai soggetti stessi
- ...

Fase II: Validazione II

Studio esplorativo

Esplorazione della dimensionalità del test e della **coerenza interna** degli item
Somministrazione delle versione rifinita al passo precedente a un campione più ampio ($n \approx 200$)
Analisi esplorativa della struttura fattoriale della scala (Quante dimensioni latenti ci sono?) $\rightarrow$ Exploratory Factor Analysis, la dimensionalità del tratto latente è ricavata dalla variabilità nei dati.

Quante dimensioni latenti sono necessarie per spiegare la variabilità osservata nei dati?

Fase II: Validazione III

Studio confermativo

Viene studiata la dimensionalità della struttura trovata allo step precedente per capire quanto questa sia replicabile e viene investigata la validità esterna della misura

Somministrazione della versione definitiva a un altro campione ($n \approx 200$)

Analisi confermativa della struttura fattoriale $\rightarrow$ Confirmatory Factor Analysis, la dimensionalità del tratto latente è stabilita a priori, così come le relazioni tra item e tratto latente

Il modello fattoriale è adatto a spiegare la variabilità tra i dati?

Fase II: Validazione IV

Standardizzazione e taratura

Il campione deve essere rappresentativo della popolazione target e deve essere estremamente ampio (nell'ordine delle migliaia)
Standardizzazione dei punteggi:

- Percentili
- Punteggi standardizzati, ad esempio:
  - Punti z: $z_i = \dfrac{x_i - \mu}{\sigma}$
  - Punti T: $T_i = 50 + 10z_i$

Produzione delle tavole di conversione grezzi–standardizzati

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

Prestazione Massima

Misura *quanto una persona sa* fare nelle migliori condizioni possibili o quanto una persona conosca di un determinato ambito
Questo presuppone che le domande abbiano una **risposta corretta**
Riguardano risorse cognitive, abilità, intelligenza

Prestazione Tipica

Misura *come una persona pensa/sente/si comporta* in situazioni tipiche
Eistono solo risposte personali che non sono né corrette né errate
Riguardano tratti di personalità, atteggiamenti, motivazioni, sistemi di valori (ecc.)

1 Test

2 Tipi di test
- Prestazione massima
- Prestazione Tipica

3 Scale di Risposta

4 Attendibilità

5 Validità

Valutano il livello massimo di abilità o competenza che un individuo può raggiungere.

Alcune caratteristiche:

- Esiste una risposta corretta (e.g., Matrici di Raven) o una risposta più corretta delle altre (e.g., Situational Judgment Test)
- L'accuratezza e/o la velocità complessiva sono la misura da cui parte l'inferenza per il costrutto latente
- Richiedono che la persona sia concentratata e svolga uno sforzo cogntivo attivo per la loro compilazione
- Possono avere un limite di tempo

In caso di test a risposta chiusa, l'item è composto da:

- **Item stem**: La domanda a cui dare una risposta, fornisce lo stimolo di partenza
- **Le alternative di risposta**:
  - La risposta corretta (una sola)
  - Il o i distrattori, ovvero delle risposte errate

In caso di test a risposta chiusa, l'item è composto da:

- **Item stem**: La domanda a cui dare una risposta, fornisce lo stimolo di partenza
- **Le alternative di risposta**:
  - La risposta corretta (una sola)
  - Il o i distrattori, ovvero delle risposte errate

Qual è la capitale della Francia?

1. Parigi
2. Montpellier
3. Marseille
4. Toulouse

1. Parigi
2. Roma
3. Londra
4. Dakar

Possono essere utilizzati per la selezione del personale:

- Matrici di tipo Raven (valutazione dell'intelligenza fluida e del ragionamento astratto)
- Situational Judgment Test (SJT - Scenario lavorativo credibile dove viene presentata una criticità e l3 candidat3 deve trovare la strategia risolutiva migliore)

Validità e sviluppo SJT

La validità concerne principalmente il tipo di scenario più che la metodologia in sé
Lo sviluppo richiede l'analisi e conoscenza approfondita delle dinamiche aziendali e dei vari problemi emersi, da cui sviluppare gli scenari ipotetici con le possibili strategie risolutive. Questo processo ora è parzialmente svolto grazie all'IA.

Azienda di cosmetica e cura per il corpo deve assumere del nuovo personale.

Valori aziendali:

- Customer experience personalizzata
- Lavoro di squadra
- Efficienza operativa
- Gestione dello stress

Scenario

Sei in negozio in un momento di forte affluenza. Una cliente appare indecisa davanti ai prodotti skincare e osserva le etichette con esitazione. Nel frattempo:

- un collega ti chiede aiuto alla cassa perché c'è fila,
- un'altra cliente ti sta aspettando per pagare.

Cosa fai?

A. Mi concentro sulla cliente indecisa per offrirle una consulenza completa.

B. Le offro un consiglio mirato e rapido, poi mi sposto ad aiutare in cassa.

C. Vado subito ad aiutare il collega in cassa, chiedendo alla cliente di aspettare.

D. Chiedo al collega di aspettare e continuo con la cliente che stavo seguendo prima.

Scenario

Sei in negozio in un momento di forte affluenza. Una cliente appare indecisa davanti ai prodotti skincare e osserva le etichette con esitazione. Nel frattempo:

- un collega ti chiede aiuto alla cassa perché c'è fila,
- un'altra cliente ti sta aspettando per pagare.

Cosa fai?

A. Mi concentro sulla cliente indecisa per offrirle una consulenza completa.

B. Le offro un consiglio mirato e rapido, poi mi sposto ad aiutare in cassa.

C. Vado subito ad aiutare il collega in cassa, chiedendo alla cliente di aspettare.

D. Chiedo al collega di aspettare e continuo con la cliente che stavo seguendo prima.

Ordine dalla più alla meno adeguata:

1° posto – B Equilibrio tra attenzione al cliente e supporto al team. Dimostra flessibilità, gestione delle priorità e orientamento sia al cliente sia all'efficienza.

2° posto – A Forte orientamento alla customer experience, ma rischio di trascurare il flusso operativo e il lavoro di squadra.

3° posto – C Buona attenzione all'efficienza e al team, ma minore cura dell'esperienza personalizzata del cliente.

4° posto – D Scarsa flessibilità e limitata collaborazione; non integra le diverse richieste della situazione.

1 Test

2 Tipi di test
- Prestazione massima
- Prestazione Tipica

3 Scale di Risposta

4 Attendibilità

5 Validità

Valutano pattern abituali di comportamento, pensiero e vissuto emotivo.

Alcune caratteristiche:

- Nessuna risposta giusta o sbagliata
- Basati sulla capacità introspettiva della persona: Lo sforzo richiesto è rivolto verso sé stessi
- In alcuni casi, le persone possono mentire (desiderabilità sociale)
- Scale di risposta con vari formati, tutti ugualmente accettabili

Test di personalità, questionari per la valutazione degli atteggiamenti, opinioni ecc.

Caratteristica	Prestazione massima	Prestazione tipica
Cosa misura	Abilità	Tratti e comportamenti
Risposte corrette	Sì	No
Sforzo richiesto	Alto e intenzionale	Riflessivo/auto-descrittivo
Esempi	Test cognitivi	Questionari di personalità
Uso in azienda	Selezione capacità	Fit organizzativo

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

Sono item formulati in modo che l'unica possibile risposta possa essere Sì/No o Vero/Falso

Esempio

Mi commuovo quando vedo un film drammatico.

- *Sì*
- *No*

Sono item formulati in modo che l'unica possibile risposta possa essere Sì/No o Vero/Falso

Esempio

Mi commuovo quando vedo un film drammatico.

- *Sì*
- *No*

Vantaggi

Sono estremamente facili da comprendere per chiunque

Svantaggi

La scala di risposta potrebbe essere troppa riduttiva e particolarmente complessa per certe tipologie di persone

Usati sia per prestazione tipica sia massima

Risolvere il problema(?)

Aggiunta di un terzo punto, ad esempio "Non so", "A volte", "Dipende" ecc.:

Mi commuovo quando vedo un film drammatico

- ☐ Sì
- ☐ No
- ☐ A volte

Risolvere il problema(?)

Aggiunta di un terzo punto, ad esempio "Non so", "A volte", "Dipende" ecc.:

Mi commuovo quando vedo un film drammatico

- ☐ Sì
- ☐ No
- ☐ A volte

- ☐ Sì
- ☐ A volte
- ☐ No

Di fatto... chi sceglie l'alternativa "A volte" si commuove... come trattarlo in sede di analisi dei dati?

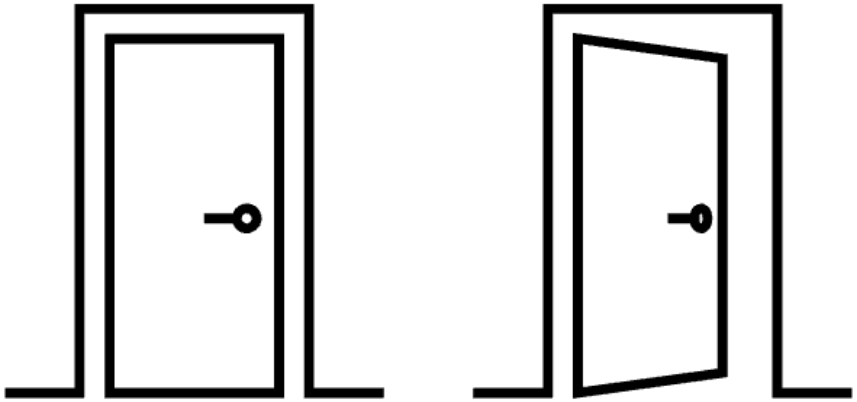

Preferisco un lavoro nel quale:

1. *Posso crescere come persona*
2. *Posso guadagnare bene*
3. *Posso imparare cose nuove*

Le opzioni di risposta sono realmente ordinabili? Sono anche solo comparabili?

Narcissistic Personality Inventory

1. non sono né meglio né peggio di altre persone
2. penso di essere una persona speciale

Una persona con un alto livello di narcisismo ha più probabilità di scegliere la seconda opzione

In prestazione massima sono i tipici item a risposta multipa

L'evoluzione delle scale con item Sì/No o Vero/Falso → aggiunta di livelli intermedi

Summating rating scales: Scale composte da diverse domande (**item**) il cui punteggio totale è ottenuto attraverso la somma dei punteggi alle valutazioni fornite ad ogni item

L'evoluzione delle scale con item Sì/No o Vero/Falso → aggiunta di livelli intermedi

Summating rating scales: Scale composte da diverse domande (**item**) il cui punteggio totale è ottenuto attraverso la somma dei punteggi alle valutazioni fornite ad ogni item

Assunzione

Il costrutto latente si muove lungo un continuum sottostante alle opzioni di risposte, ovvero è possibile dare una quantità alla variabile psicologica misurata a seconda dell'opzione di risposta scelta.

Esprimere il proprio livello di accordo con l'affermazione "Sono una persona organizzata" secondo le seguenti opzioni di risposta:

Per niente d'accordo: ☐ ☐ ☐ ☐ ☐: Completamente d'accordo

L'assunzione è che il livello di accordo con l'affermazione vari lungo un continuum e che questo continuum sia delimitato dagli ancoraggi "Per niente d'accordo" e "Completamente d'accordo":

Esprimere il proprio livello di accordo con l'affermazione "Sono una persona organizzata" secondo le seguenti opzioni di risposta:

Per niente d'accordo: ☐ ☐ ☐ ☐ ☐: Completamente d'accordo

L'assunzione è che il livello di accordo con l'affermazione vari lungo un continuum e che questo continuum sia delimitato dagli ancoraggi "Per niente d'accordo" e "Completamente d'accordo":

☐ ☐ ☐ ☐ ☐

Completamente in disaccordo — Completamente d'accordo

Rating Scales (Scale Likert)

☐ ☐ ☐ ☐ ☐

Completamente in disaccordo — Completamente d'accordo

☐ ☐ ☐ ☐ ☐

Completamente in disaccordo — Completamente d'accordo

☐ ☐ ☐ ☐ ☐

Completamente in disaccordo — Completamente d'accordo

☐ ☐ ☐ ☐ ☐

Completamente in disaccordo — Completamente d'accordo

"Sono una persona organizzata"

Indicare il grado di accordo con l'affermazione

Barrare il valore numerico corrispondente

Per niente				Completamente
1	2	3	4	5

Barrare la casella

Per niente				Completamente
☐	☐	☐	☐	☐

Segnare il numero

"Sono una persona organizzata": ☐

Visual Analougue Scale

Molto utilizzate anche in psicologia dello sviluppo

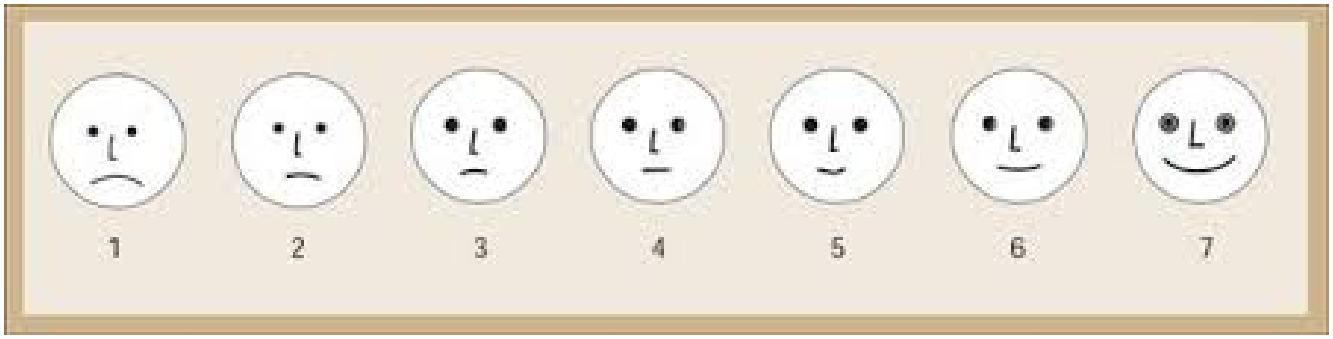

Accordo

Indicare il grado di accordo con un'affermazione
Ad esempio:
Sono una persona organizzata

Per niente d'accordo: ☐ ☐ ☐ ☐ ☐: Completamente d'accordo

Intensità

Dare una valutazione vera e propria rispetto a un argomento in termini di buono/cattivo, insufficiente/sufficiente, importante/non importante, eccetera.
Ad esempio:
Indicare il proprio livello di competenze informatiche

5 = alto; 4 = medio-alto; 3 = medio; 2 = medio-basso; 1 = basso

Frequenza

Indicare la frequenza con cui vengono messi in atto i comportamenti o vengono sperimentati i vissuti descritti dall'item
Ad esempio:
Nell'ultimo anno, mi sono sentito ansioso:

Mai ☐ Raramente ☐ Qualche volta ☐ Spesso ☐ Sempre ☐

Frequenza

Indicare la frequenza con cui vengono messi in atto i comportamenti o vengono sperimentati i vissuti descritti dall'item
Ad esempio:
Nell'ultimo anno, mi sono sentito ansioso:

Mai ☐ Raramente ☐ Qualche volta ☐ Spesso ☐ Sempre ☐

Attenzione!

Cosa vuole dire "Spesso"? E "Qualche volta"? Vogliono dire la stessa cosa per tutt*?

Bassa frequenza

1. Mai
2. Circa una volta l'anno
3. Circa due volte l'anno
4. Due volte al mese
5. Più di due volte al mese

Alta frequenza

1. Due volte al mese o meno
2. Una volta a settimana
3. Due volte a settimana
4. Tutti i giorni
5. Diverse volte al giorno

Rating scales: Domini

Comportamento	Mai	Raramente	Qualche volta	Spesso	Sempre
Scrollare Instagram					
Controllare WhatsApp					
Andare al cinema					

Rating scales: Domini

Comportamento	Mai	Raramente	Qualche volta	Spesso	Sempre
Scrollare Instagram					
Controllare WhatsApp					
Andare al cinema					

Comportamento	Mai	Raramente	Qualche volta	Spesso	Sempre
Fare lo spid					
Aprire un conto in banca					
Andare al cinema					

Come regola generale, più è alto il numero di punti della scala, maggiore è poi l'attendibilità della misura
Solitamente si considerano scale con un numero di punti tra 4 e 7 $\rightarrow$ Più di 7 punti sono "Inutili"
Numero dispari o numero pari di punti?
Un numero dispari di punti permette l'alternativa neutra:

- Ci sono dei casi (e.g., valutazione di soddisfazione per un servizio) dove ha senso avere un'alternativa neutra
- In altri casi (e.g., valutazione degli atteggiamenti verso un gruppo sociale) l'alternativa neutra funge da "rifugio" per non sbilanciarsi

Acquiescienza

Essere sistematicamente d'accordo con le affermazioni proposte dagli item

Estremismo

Scegliere sempre le risposte estreme

Evasività

Scegliere sempre i punti centrali della scala o le risposte "Non so"

Desiderabilità sociale

Rispondere in modo da mostrarsi delle belle persone sempre e comunque

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

Grado in cui una procedura di misurazione produce lo stesso risultato in prove ripetute

$$X = V + E$$

dove:
X: misura rilevata
V: parte vera
E: errore: fluttuazioni casuali oppure costante e sistematico

L'attendibilità di una misura è la proporzione di X che non riflette l'errore di misurazione:

$$\rho = \frac{V}{V + E}$$

L'errore E

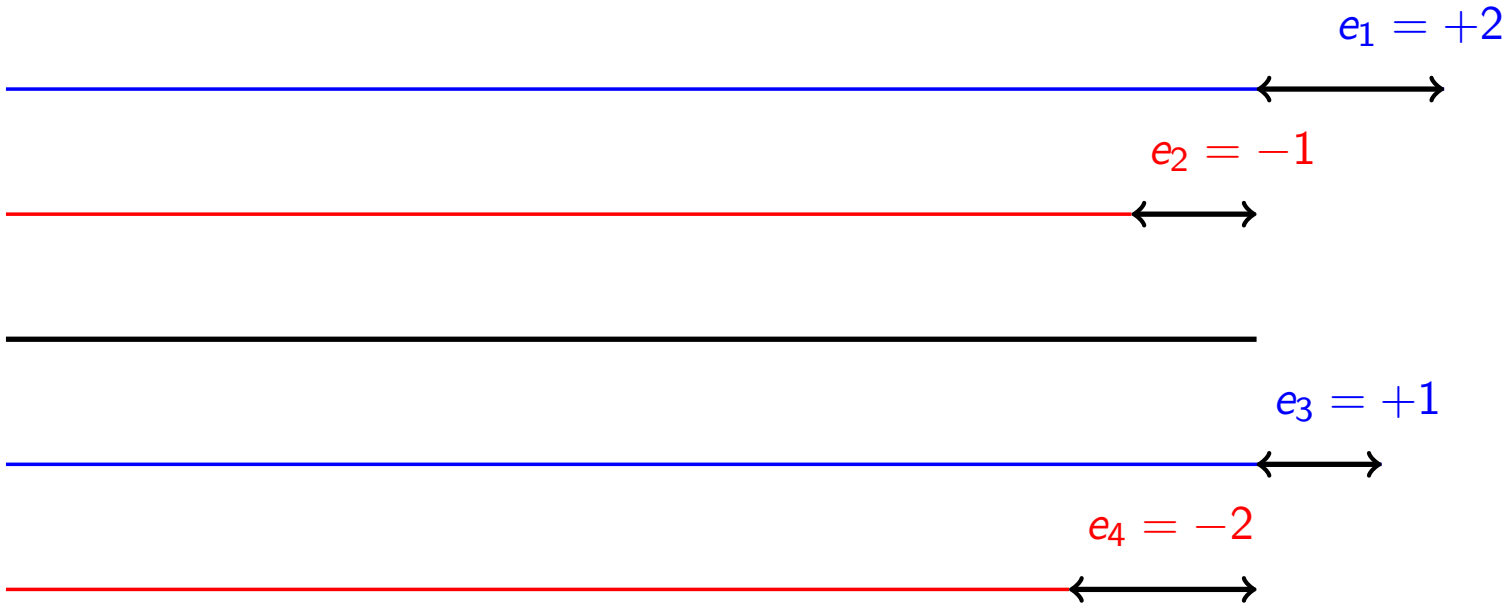

- La media degli errori è 0

  $$(+2) + (-1) + (+1) + (-2) = 0$$

- La correlazione fra punteggio vero ed errore è zero

  L'errore cambia sempre indipendentemente e imprevedibilmente, indipendentemente dalla linea nera

- La correlazione fra errore e punteggio vero alla misurazione successiva è zero

  L'errore alla prima misurazione non influenza l'errore alla seconda misurazione

- La correlazione fra errori di misurazioni diverse è zero

  Ogni errore è unico

L'errore E

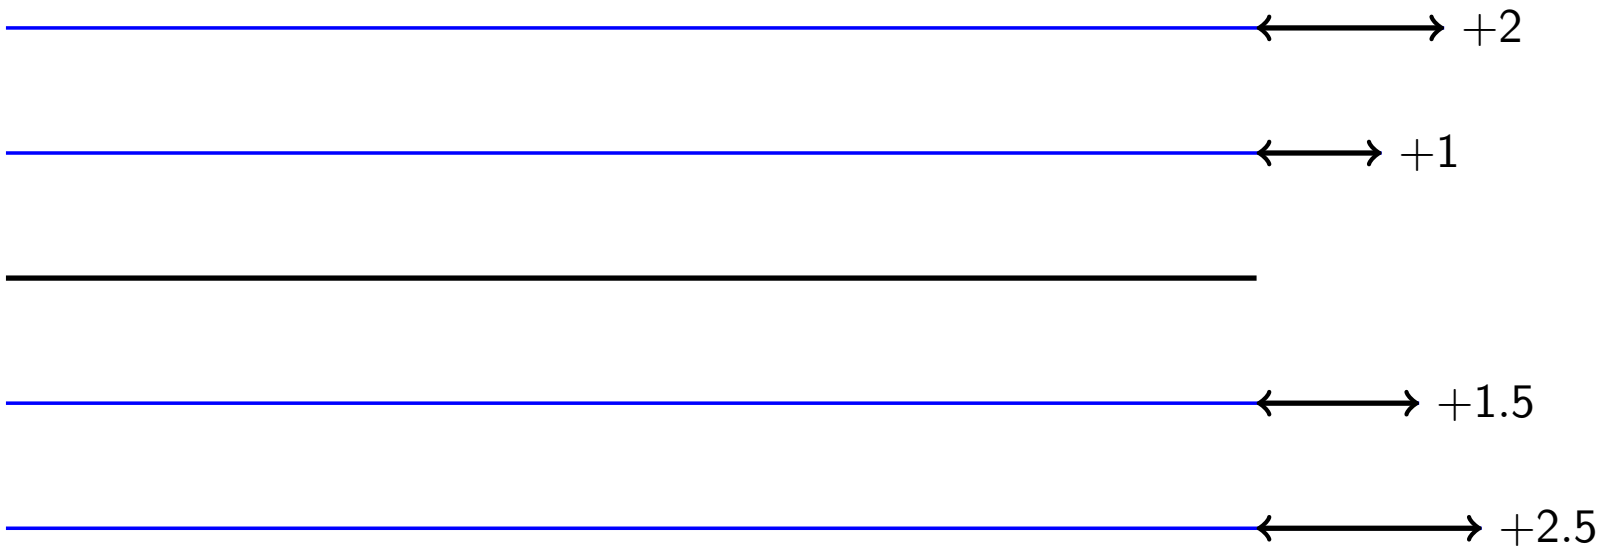

L'errore va sempre dalla stessa parte $\rightarrow$ è sistematico (bias)

L'errore E

Errore casuale

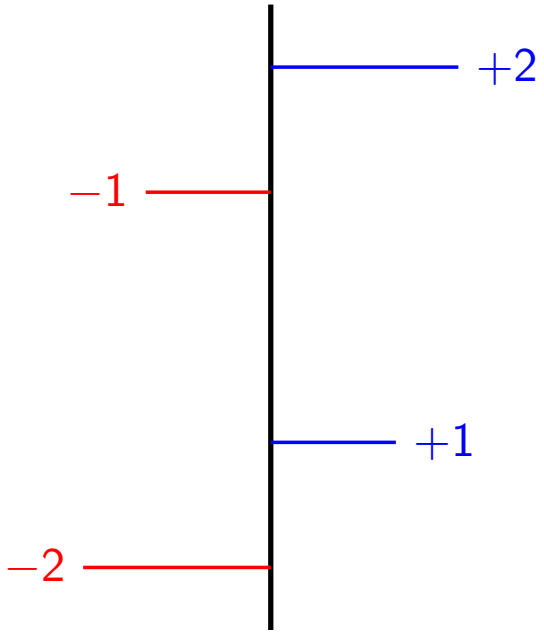

Bias (errore sistematico)

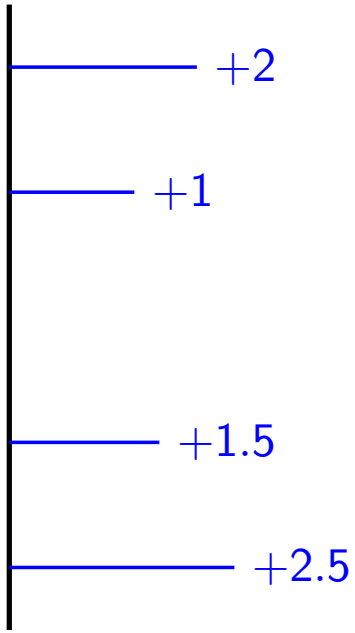

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità
- Validità di costrutto
- Validità Statistica
- Validità Interna
- Validità esterna
- Validità ecologica

Quello che si sta misurando... è proprio quello che si voleva misurare e non altro!

(Alcuni) Elementi utili per la validità di costrutto:

- Chiara definizione del costrutto teorico
- Misurare il costrutto con metodi differenti

Convergente

La misura di interesse correla con misure che misurano lo stesso costrutto o *costrutti simili*

Esempio

La leadership misurata con un nuovo questionario correla fortemente con la leadership misurata con il gold standard.

Divergente/Discriminante

La misura di interesse NON correla con misure che misurano costrutti diversi

Esempio

La nuova misura della leadership non correla con una misura per la mindfulness.

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità
- Validità di costrutto
- Validità Statistica
- Validità Interna
- Validità esterna
- Validità ecologica

Quello che stiamo inferendo a partire dalle analisi ha senso perché le analisi hanno senso!
(Alcuni) Elementi utili per la validità statistica:

- Appropriatezza dei metodi statistici utilizzati sulla base delle variabili misurate
- Adeguatezza dell'ampiezza campionaria

Le analisi statistiche applicate per fare inferenze (a livello di popolazione o di varibaili latenti) hanno bisogno di essere sensate e pensate dati i limiti dei dati osservati:

- ampiezza campionaria adeguata
- scelta del modello statistico coerente con la propria teoria
- equilibrio tra quello che si vuole ottenere e le caratteristiche reali del dato/campione

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità
- Validità di costrutto
- Validità Statistica
- Validità Interna
- Validità esterna
- Validità ecologica

I risultati osservati in uno studio riflettono realmente l'effetto della variabile indipendente sulla variabile dipendente, senza essere distorti da fattori confondenti

(Alcuni) Elementi utili per la validità esterna:

- Controllo di fattori esterni e variabili confondenti
- Disegni sperimentali appropriati (randomizzazione, gruppo di controllo)
- Misurazioni valide e attendibili

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità
- Validità di costrutto
- Validità Statistica
- Validità Interna
- Validità esterna
- Validità ecologica

Il grado in cui i risultati sono *rappresentativi* della popolazione di interesse e il grado in cui sono *replicabili*

(Alcuni) Elementi utili per la validità esterna:

- Il campione è rappresentativo della popolazione target
- La validità ecologica

Esempio

Il nuovo questionario per la leadership è stato somministrato a un campione di studenti e studentesse universatari. I risultati sono generalizzabili (validi) alla popolazione dell student iscritt al corso di studio, NON per la popolazione dei manager aziendali.

1 Test

2 Tipi di test

3 Scale di Risposta

4 Attendibilità

5 Validità
- Validità di costrutto
- Validità Statistica
- Validità Interna
- Validità esterna
- Validità ecologica

Rappresenta la generalizzabilità dei risultati di una ricerca a quella che è la vita quotidiana
I dati raccolti devono essere rappresentativi del comportamento dell'individuo nella sua realtà abituale
Il problema degli esperimenti di laboratorio, dei questionari, degli scenari... non sono la vita reale.
Il laboratorio fornsice la possibilità di avere un alto controllo rispetto alle manipolazioni sperimentali e alle variabili confondenti. Tuttavia è un ambiente molto molto finto e lontano dall'ambiente in cui le persone agiscono normalmente.